



Universidad Nacional Autónoma de México
Instituto de Investigaciones en Matemáticas Aplicadas y en Sistemas




Taller:

Ciencia de datos con PySpark

Blanca Vázquez
blanca.vazquez@iimas.unam.mx

¿Qué es PySpark?



Hola, ¿Qué es Pyspark?

Hola 😊

PySpark es la **API de Apache Spark para Python**. Permite usar el motor de procesamiento distribuido de Spark escribiendo código en Python.

En términos simples:


👉 **PySpark sirve para procesar y analizar grandes volúmenes de datos de forma rápida y distribuida.**

¿Para qué se usa PySpark?

- **Big Data:** manejar datasets muy grandes que no caben en memoria.
- **Procesamiento distribuido:** ejecuta tareas en varios núcleos o máquinas al mismo tiempo.
- **ETL** (extracción, transformación y carga de datos).
- **Análisis de datos y machine learning** a gran escala.
- **Streaming** de datos en tiempo real.

Componentes principales

- **Spark SQL:** trabajar con datos estructurados (similar a SQL).
- **DataFrames:** tablas distribuidas, parecidas a pandas pero escalables.
- **RDDs:** estructuras de datos distribuidas de bajo nivel.
- **MLlib:** librería de machine learning.
- **Spark Streaming / Structured Streaming:** procesamiento de datos en tiempo real.



Hola, ¿Qué es Pyspark?

Hola 😊

PySpark es la **API de Apache Spark para Python**. Permite usar el motor de procesamiento distribuido de Spark escribiendo código en Python.

En términos simples:

👉 **PySpark sirve para procesar y analizar grandes volúmenes de datos de forma rápida y distribuida.**

¿Para qué se usa PySpark?

- **Big Data:** manejar datasets muy grandes que no caben en memoria.
- **Procesamiento distribuido:** ejecuta tareas en varios núcleos o máquinas al mismo tiempo.
- **ETL** (extracción, transformación y carga de datos).
- **Análisis de datos y machine learning** a gran escala.
- **Streaming** de datos en tiempo real.

Componentes principales

- **Spark SQL:** trabajar con datos estructurados (similar a SQL).
- **DataFrames:** tablas distribuidas, parecidas a pandas pero escalables.
- **RDDs:** estructuras de datos distribuidas de bajo nivel.
- **MLlib:** librería de machine learning.
- **Spark Streaming / Structured Streaming:** procesamiento de datos en tiempo real.

Hola, ¿Qué es Pyspark?



¡Hola! **PySpark** es la biblioteca de **Python** para usar **Apache Spark**, un motor de procesamiento de datos distribuido de código abierto diseñado para big data y computación en clúster.

Te explico en términos sencillos:

¿Qué es Apache Spark?

Spark es un framework que permite procesar **grandes volúmenes de datos** (terabytes o petabytes) dividiendo el trabajo entre múltiples computadoras (clúster), de manera mucho más rápida que herramientas tradicionales como Hadoop MapReduce.

PySpark en pocas palabras:

Es la **Interfaz de Python** para Spark. Te permite usar todas las capacidades de Spark escribiendo código en Python, un lenguaje muy popular y fácil de aprender.

Características principales:


1. **Procesamiento distribuido:** Divide automáticamente los datos y cálculos en un clúster.
2. **Velocidad:** Hasta 100 veces más rápido que Hadoop para ciertas operaciones (usa memoria RAM en lugar de solo disco).
3. **Tolerancia a fallos:** Si un nodo falla, Spark puede recuperarse automáticamente.

Casos de uso comunes:

- **Procesamiento de datos a gran escala** (ETL)
- **Análisis exploratorio** de grandes datasets
- **Machine Learning** con grandes volúmenes de datos
- **Procesamiento en tiempo real** (streaming)
- **Limpieza y transformación** de datos

Todo claro con PySpark, ¿no?

...pero, ¿de dónde surgió la idea?






Alguna vez te has preguntado: ¿cuántos datos generas diariamente?

- Mensajes de texto
 - Llamadas telefónicas
 - Correos electrónicos
 - Fotos
 - Videos
 - Música
 - Búsquedas en la web


What Happens on the Internet IN A SINGLE DAY?




Figures rounded.
Source: Exploding Topics (Feb 2025)









What Happens on the Internet IN A SINGLE DAY?




Figures rounded.
Source: Exploding Topics (Feb 2025)










**¿Cómo clasificar cualquier dato
como Big data?**



¿Cómo clasificar cualquier dato como Big data?


Las 5v's del Big Data




Las 5v's del Big Data




Las 5v's del Big Data



Escenario real de las 5v's del Big Data



**¿Cómo almacenar y procesar
estos datos masivos?**





¿Cómo almacenar y procesar datos masivos?



Apache Hadoop

Es un entorno de trabajo de software de código abierto que permite el procesamiento y análisis distribuido de grandes volúmenes de datos.




Apache Hadoop

Es un entorno de trabajo de software de código abierto que permite el procesamiento y análisis distribuido de grandes volúmenes de datos.



Sistema de archivos distribuido (Hadoop Distributed File System)




500 MB

Apache Hadoop

Es un entorno de trabajo de software de código abierto que permite el procesamiento y análisis distribuido de grandes volúmenes de datos.



Sistema de archivos distribuido (Hadoop Distributed File System)




Apache Hadoop

Es un entorno de trabajo de software de código abierto que permite el procesamiento y análisis distribuido de grandes volúmenes de datos.




Sistema de archivos distribuido (Hadoop Distributed File System)




Apache Hadoop

Es un entorno de trabajo de software de código abierto que permite el procesamiento y análisis distribuido de grandes volúmenes de datos.



Sistema de archivos distribuido (Hadoop Distributed File System)



Servidores de fragmentos:



- Fragmentos continuos de 16 - 64 MB
- Réplicas de 2 a 3 veces

Apache Hadoop

Es un entorno de trabajo de software de código abierto que permite el procesamiento y análisis distribuido de grandes volúmenes de datos.



Sistema de archivos distribuido (Hadoop Distributed File System)




Servidor de fragmentos
(chunks)


Garantizar:

- Persistencia
- Replicabilidad
- Disponibilidad


Map Reduce



Map Reduce




Map Reduce



Resultado



Procesamiento en paralelo
(Parallel processing)

¿Dónde se ejecutan estos procesos?




Arquitectura basada en clúster

Modelo
básico computacional




Arquitectura basada en clúster

Modelo
básico computacional




1 Gbps entre cualquier
par de nodos en un rack



Cada rack tiene de 16 - 64 nodos


Arquitectura basada en clúster

Modelo
básico computacional



2-10 Gbps entre racks

1 Gbps entre cualquier
par de nodos en un rack




Cada rack tiene de 16 - 64 nodos

Arquitectura basada en clúster



Imagen tomada de J. Leskovec, A. Rajaraman, J. Ullman: Mining of Massive Datasets



Google Data Centers: Building for Everyone



Imagen tomada de Google data centers
https://datacenters.google/intl/es-419_ALL/

Unified engine for large-scale data analytics

GET STARTED

What is Apache Spark™?

Apache Spark™ is a multi-language engine for executing data engineering, data science, and machine learning on single-node machines or clusters.

Python

SQL

Scala

Java

R



Apache Spark

+




Python

=



PySpark



Contacto

Dra. Blanca Vázquez

blanca.vazquez@iimas.unam.mx

<https://github.com/blancavazquez>

<https://iimas.unam.mx/arbio>

